
USO DE EYE TRACKER E MACHINE LEARNING PARA ANÁLISE DO COMPORTAMENTO VISUAL DE CONDUTORES DE TRÂNSITO

Bruno Arthur Basso Silva¹, Gabriela Molina Ciocci², Guilherme Barboza de Albuquerque³, Sérgio Martins de Oliveira Santos⁴, Victor P. Varela⁵

¹ Ciência da Computação - campus São Bernardo do Campo

brunobasso.contato@gmail.com, unifgciocci@fei.edu.br, unifgalbuquerque@fei.edu.br,

sergiomos2010@gmail.com, vvarelar@fei.edu.br

Orientador: Victor P. Varela

Departamento de Ciência da Computação, Centro Universitário FEI

vvarelar@fei.edu.br

Resumo: WIP

Palavras-chaves: Comportamento de Motoristas, Eye Tracking, IA, Pupil Core, Detectron2

I. Introdução

A segurança no trânsito permanece como um dos principais desafios globais, demandando contribuições multidisciplinares das áreas de Engenharia de Transportes, Ciência de Dados e Interação Humano-Máquina (IHM). Segundo a Organização Mundial da Saúde (OMS), os acidentes de trânsito continuam entre as principais causas de mortes e ferimentos graves em todo o mundo, resultando em aproximadamente 1,19 milhão de mortes por ano [1]. Nesse contexto, a OMS lançou a Década de Ação pela Segurança no Trânsito 2021–2030, acompanhada do Plano Global para a Década de Ação pela Segurança no Trânsito, que estabelece como meta a redução de pelo menos 50% no número de mortes e lesões causadas pelo trânsito até 2030 [1].

Um estudo publicado por Amini et al. (2023) [2] evidenciou que, embora existam investimentos constantes em segurança — como faixas mais visíveis, melhores sinalizações e sistemas automáticos nos veículos —, o comportamento humano ainda é um fator determinante que contribui para a prevenção de acidentes. A forma como o motorista observa o ambiente, reage a imprevistos e identifica riscos pode representar a diferença entre uma direção segura e uma situação de perigo iminente. Nesse sentido, o estudo destaca o papel da atenção visual e da tomada de decisão, apontando a distração cognitiva e visual como uma das causas de falhas na condução, mesmo quando o motorista se encontra em condições controladas de simulação.

Aprofundando essa análise, os autores investigaram o impacto do uso do celular durante a condução em ambiente simulado, avaliando o comportamento visual dos motoristas por meio de rastreamento ocular (do inglês Eye Tracking). Os resultados mostraram

que a leitura e o envio de mensagens de texto durante a direção alteram significativamente o padrão de fixação ocular, desviando o foco visual da via e comprometendo o controle lateral do veículo. Essa alteração de atenção levou a um aumento da variabilidade na trajetória e a uma redução na estabilidade direcional, evidenciando que a distração compromete tanto a percepção visual quanto o desempenho motor do condutor, mesmo em contextos experimentais controlados [2].

De forma complementar, estudos recentes demonstram a aplicação de técnicas de Machine Learning para análise de comportamento visual de condutores. Behboudi et al. (2024) [3] realizaram uma revisão abrangente de técnicas de aprendizado de máquina aplicadas à análise e predição de acidentes de trânsito, categorizando metodologias que variam desde modelos estatísticos clássicos até arquiteturas de Deep Learning, incluindo CNNs e Redes Neurais Recorrentes (RNNs), aplicadas à classificação de padrões de risco e predição de colisões a partir de dados multimodais de sensores veiculares e comportamento do motorista. Complementarmente, Aydin et al. (2024) [4] propuseram um método baseado em processamento de imagens para analisar o comportamento visual de motoristas utilizando dados de eye tracker, segmentando o campo visual em regiões de interesse (ROIs) e quantificando métricas como tempo de permanência do olhar (dwell time) e frequência de fixações em áreas críticas — como espelhos retrovisores, painel de instrumentos e via à frente — permitindo identificar padrões atencionais associados à condução segura. Esses ambientes permitem a coleta de dados precisos sobre padrões de fixação ocular, respostas a estímulos externos e técnicas de treinamento cognitivo, especialmente entre condutores in-

experientes, fornecendo subsídios quantitativos para o desenvolvimento de sistemas de assistência ao motorista baseados em IA [2], [3].

Dessa forma, a literatura evidencia que, embora os ambientes simulados sejam úteis para compreender e mensurar o comportamento visual de condutores em condições controladas, ainda persiste uma lacuna entre o comportamento observado nesses cenários e aquele manifestado em situações reais de tráfego — nas quais múltiplos estímulos, imprevisibilidade e fatores ambientais influenciam a atenção e a resposta do motorista. Essa discrepância foi detalhada por Arias-Portela et al. (2024) [5], no estudo "Driving Reality vs. Simulator: Data Distinctions", publicado na revista *Electronics* (MDPI). Os autores coletaram 390 gravações em condução real e 1.829 em ambiente simulado, resultando em 69.512 janelas de dados (44.225 do simulador e 25.287 da condução real), analisadas por meio de sensores embarcados, rastreamento ocular e técnicas de Inteligência Artificial (IA), alcançando 86,5 % de acurácia [5]. Essas pesquisas reforçam que, embora os simuladores proporcionem controle experimental, eles ainda não reproduzem a complexidade perceptiva e cognitiva do mundo real. Diante dessa lacuna, o presente estudo propõe analisar o comportamento visual de condutores em ambiente real, comparando motoristas experientes e inexperientes com o uso de técnicas de Inteligência Artificial (IA) e rastreamento ocular.

II. Revisão Bibliográfica

Esta seção apresenta uma revisão bibliográfica das principais tecnologias utilizadas no contexto da condução veicular e análise do comportamento do motorista. O objetivo é fundamentar teoricamente as abordagens utilizadas neste trabalho, explorando três pilares tecnológicos essenciais: Eye Tracking (rastreamento ocular), detecção de faixas (lane detection) e frameworks de visão computacional, com ênfase no Detectron2. A tecnologia de Eye Tracking permite quantificar padrões de atenção visual do condutor, fornecendo métricas objetivas sobre a distribuição do olhar durante a condução [6], [7]. Por sua vez, a detecção de faixas constitui uma técnica fundamental em sistemas de assistência ao motorista (ADAS), possibilitando o reconhecimento em tempo real das delimitações da via [8], [9]. Complementarmente, frameworks de visão computacional, como o Detectron2, oferecem arquiteturas robustas para detecção e segmentação de objetos, viabilizando a identificação automática de elementos relevantes no contexto de tráfego [10], [11], [12]. A integração desses componentes tecnológicos fundamenta a metodologia proposta para análise da correlação entre atenção visual e comportamento de condução segura.

A. Eye Tracking

O Eye Tracking é uma tecnologia que possibilita o monitoramento e o registro dos movimentos oculares de um indivíduo, permitindo a captura de métricas precisas como fixações (períodos em que o olhar permanece estático sobre um ponto), sacadas (movimentos rápidos entre fixações) e áreas de interesse (Areas of Interest - AOIs). Salvucci e Goldberg (2000) [6] propuseram algoritmos de identificação automática de fixações e sacadas em protocolos de rastreamento ocular, apresentando três abordagens principais: algoritmo baseado em velocidade (velocity-based), que identifica fixações quando a velocidade angular do olhar cai abaixo de um limiar (tipicamente 30°/s); algoritmo baseado em dispersão (dispersion-based), que agrupa pontos consecutivos dentro de uma janela espacial limitada e algoritmos híbridos que combinam critérios temporais e espaciais, permitindo classificação robusta de eventos oculares mesmo em dados ruidosos. Complementarmente, Victor et al. (2005) [7] investigaram a sensibilidade de métricas oculares à dificuldade de tarefas secundárias durante a condução, demonstrando que o aumento da carga cognitiva (induzido por tarefas visuais e auditivas) resultou em redução de 15-25% na taxa de verificação de espelhos retrovisores e aumento de 30-50% na duração média de fixações na via central, indicando estreitamento do campo atencional sob demanda cognitiva elevada. Tal abordagem fornece dados objetivos sobre o comportamento visual, sendo aplicada na análise do desempenho de motoristas em contextos reais ou simulados de direção [7], [13].

Estudos sugerem que o rastreamento ocular permite comparar a eficiência visual entre condutores com diferentes níveis de experiência, identificando padrões característicos de atenção visual que distinguem motoristas experientes de inexperientes. Chapman e Underwood (1998) [14] investigaram padrões de busca visual em motoristas novatos com e sem treinamento formal, utilizando rastreamento ocular durante condução em vias urbanas. Os resultados demonstraram que motoristas treinados apresentaram uma distribuição de fixações significativamente mais ampla no campo visual horizontal (scanning horizontal mais extenso), verificando espelhos retrovisores e pontos laterais com frequência 40% superior aos não treinados. Adicionalmente, condutores experientes exibiram fixações mais curtas (média de 180-220 ms) e maior taxa de sacadas por segundo, indicando uma estratégia de varredura visual ativa e antecipatória, enquanto condutores inexperientes mantiveram fixações prolongadas (*i.* 300 ms) concentradas na região central da via, caracterizando um padrão reativo e de menor amplitude espacial. Adicionalmente, o rastreamento ocular tem sido empregado para investigar fenômenos como fadiga, distração e carga cognitiva durante a condução, fornecendo subsídios para o desenvolvimento de sistemas de alerta e assistência ao

motorista [e.g. 15, 16, 17, 18].

B. Pupil Core

O Pupil Core, desenvolvido pela empresa alemã Pupil Labs, é um sistema portátil de rastreamento ocular (mobile eye tracker) projetado para capturar movimentos oculares em ambientes dinâmicos [19]. O equipamento consiste em um headset (óculos adaptados) leve equipado com câmeras de alta resolução: uma câmera voltada para os olhos do usuário, que registra as pupilas e reflexos corneais, e outra câmera frontal (world camera), que captura a cena visual observada pelo participante [20]. Essa configuração permite correlacionar precisamente onde o indivíduo está olhando no ambiente real.

O Pupil Core opera com uma taxa de amostragem de até 200 Hz (Hertz), ou seja, captura até 200 imagens por segundo dos movimentos oculares. Essa alta frequência de amostragem é essencial para detectar movimentos rápidos dos olhos (sacadas), que podem durar apenas 20-40 milissegundos [6]. Adicionalmente, o sistema incorpora algoritmos de compensação de deslizamentos (slippage compensation), que corrigem automaticamente pequenos deslocamentos do headset sobre a cabeça durante o uso prolongado, mantendo a calibração precisa [19].

Em condições ideais de calibração, o equipamento atinge aproximadamente $0,60^\circ$ (graus) de acurácia angular — uma medida que indica quão próximo o sistema identifica a posição real do olhar — e $0,02^\circ$ de precisão — que representa a consistência das medições repetidas no mesmo ponto [21]. Para contextualizar, $0,60^\circ$ corresponde aproximadamente à largura de um polegar a um braço de distância, demonstrando a capacidade do equipamento de detectar variações sutis nos padrões de fixação ocular durante a condução.

Uma vantagem do Pupil Core para estudos de condução veicular é sua robustez em cenários com movimentos da cabeça e do corpo. Enquanto sistemas de rastreamento ocular fixos (montados em telas ou painéis) perdem precisão quando o participante se move, o Pupil Core, por ser portátil e vestível, acompanha esses movimentos e mantém o registro preciso da direção do olhar [4]. Essa característica torna o equipamento adequado para coleta de dados em ambientes reais de condução, onde o motorista move a cabeça para verificar espelhos retrovisores, pontos cegos e mudanças de faixa [13].

C. Detectron2 e Visão Computacional para Ambientes Automotivos

A visão computacional constitui um componente fundamental para sistemas de análise de comportamento de motoristas e assistência à condução, viabilizando a interpretação automática de cenas visuais capturadas em ambiente veicular. Nesse contexto, frameworks robustos de detecção e segmentação de

objetos tornam-se essenciais para identificar elementos relevantes do cenário de tráfego — tais como veículos, pedestres, faixas de rodagem e sinalização — permitindo correlacionar a atenção visual do condutor com os componentes críticos do ambiente viário. Feng et al. (2020) [12] realizaram uma revisão abrangente de métodos de detecção e segmentação de objetos multi-modal para condução autônoma, analisando 180 publicações e categorizando técnicas que combinam dados de câmeras, LiDAR e radar. Os autores identificaram que arquiteturas baseadas em fusão multi-modal de sensores (sensor fusion) alcançaram acurácias superiores a 90% na detecção de pedestres e veículos em conjuntos de dados como KITTI e nuScenes, superando em 12-18% os métodos baseados exclusivamente em imagens RGB. Adicionalmente, o estudo destacou desafios persistentes, como detecção robusta em condições adversas (chuva, neblina, baixa luminosidade) e generalização para cenários não representados nos dados de treinamento, apontando a necessidade de datasets mais diversificados e técnicas de aumento de dados (data augmentation) específicas para o domínio automotivo.

O Detectron2, desenvolvido pelo Facebook AI Research (FAIR) e fundamentado na biblioteca PyTorch, é um framework de código aberto utilizado em pesquisas de visão computacional aplicada à condução automotiva [10]. A arquitetura modular do framework permite a implementação e customização de algoritmos de detecção e segmentação de objetos, oferecendo flexibilidade para adaptar modelos pré-treinados a cenários específicos de tráfego, mantendo precisão e desempenho em tempo real — característica necessária para aplicações que exigem processamento de vídeo durante a condução [12].

Entre os algoritmos implementados no Detectron2, destacam-se arquiteturas que representam diferentes abordagens para detecção e segmentação de objetos. O Faster R-CNN [22] é um modelo baseado em redes neurais convolucionais (do inglês Convolutional Neural Networks - CNNs) que utiliza uma Rede de Proposição de Regiões (do inglês Region Proposal Network - RPN) para gerar propostas de regiões candidatas à presença de objetos, subsequentemente classificadas e refinadas por uma rede de detecção. Essa abordagem de dois estágios (two-stage detection) permite equilibrar precisão e velocidade de inferência, sendo empregada em cenários onde a identificação precisa de múltiplos objetos é prioritária [22]. De forma complementar, o Mask R-CNN constitui uma extensão do Faster R-CNN que adiciona um ramo paralelo para segmentação de instâncias, gerando máscaras binárias que delimitam pixel a pixel a forma e os contornos de cada objeto detectado [11]. Essa capacidade de segmentação em nível de instância é relevante para análise de elementos viários, como delimitação de faixas de rodagem, contornos de veículos e identificação de pedestres em diferentes posturas,

fornecendo informações espaciais que transcendem a localização por caixas delimitadoras (bounding boxes) [11].

Adicionalmente, o Detectron2 implementa detectores de estágio único (single-stage detectors), como o RetinaNet, que realiza a detecção diretamente a partir de mapas de características densas, sem a etapa intermediária de geração de propostas de regiões [23]. O RetinaNet introduz a Focal Loss, uma função de custo projetada para mitigar o desequilíbrio entre classes positivas e negativas durante o treinamento, problema recorrente em cenários onde objetos de interesse (como pedestres ou ciclistas) aparecem em quantidades menores que o plano de fundo [23]. Essa propriedade torna o RetinaNet adequado para detecção de objetos pequenos ou menos frequentes no ambiente de tráfego, contribuindo para a robustez do sistema em situações de condução complexas.

A arquitetura modular do Detectron2 permite configurar dinamicamente as classes de interesse durante as fases de treinamento e inferência, viabilizando a identificação e classificação de elementos específicos do ambiente rodoviário. Entre as categorias comumente detectadas em contextos automotivos, encontram-se: faixas de rodagem e demarcações viárias; veículos de diferentes categorias (automóveis, motocicletas, caminhões, ônibus); pedestres e ciclistas em diversas configurações espaciais; sinalização vertical (placas de trânsito) e semáforos; além de elementos naturais e construídos do entorno, como árvores, postes, barreiras de proteção e edificações [12]. Essa capacidade de mapeamento detalhado do ambiente fornece subsídios para análises complexas da correlação entre atenção visual do motorista e elementos críticos do cenário de condução, permitindo investigar, por exemplo, se condutores experientes dirigem o olhar com maior frequência para áreas de risco potencial (como pedestres próximos à via) em comparação com motoristas inexperientes [13].

D. Detecção de Faixas (Lane Detection)

A detecção de faixas (Lane Detection) constitui uma tecnologia fundamental de visão computacional aplicada ao sistema ADAS, viabilizando a identificação e o rastreamento automático das marcações viárias que delimitam as faixas de rodagem [8], [9]. Essa capacidade técnica permite que sistemas embarcados em veículos monitorem continuamente o posicionamento lateral do automóvel em relação às delimitações da pista, fornecendo subsídios para funcionalidades como alerta de saída de faixa (Lane Departure Warning - LDW) e manutenção assistida de faixa (Lane Keeping Assist - LKA) [8]. No contexto da análise de comportamento de motoristas, a detecção de faixas adquire relevância adicional ao permitir correlacionar objetivamente a atenção visual do condutor com elementos críticos do ambiente viário, possibilitando investigar, por exemplo, se o motorista

dirige o olhar para as delimitações da via durante manobras de mudança de faixa ou em situações de risco iminente.

Os métodos empregados para detecção de faixas podem ser classificados em duas abordagens principais, que refletem a evolução histórica das técnicas de visão computacional: métodos clássicos baseados em processamento tradicional de imagens e métodos contemporâneos fundamentados em aprendizado profundo [9].

A primeira abordagem corresponde aos métodos clássicos, que utilizam técnicas tradicionais de processamento de imagem aplicadas sequencialmente para extrair características geométricas das faixas. O processamento típico inicia-se com a filtragem de ruído, frequentemente implementada por meio de filtros Gaussianos (Gaussian Blur), que suavizam a imagem reduzindo variações de intensidade causadas por imperfeições do sensor ou condições de iluminação variável [8]. Subsequentemente, aplica-se a detecção de bordas utilizando algoritmos como o detector de Canny [24], que identifica transições abruptas de intensidade luminosa na imagem — características típicas das delimitações entre faixas pintadas e o asfalto. A etapa final consiste na aplicação da Transformada de Hough [25], uma técnica matemática que detecta formas geométricas parametrizáveis (como linhas retas) em espaços de características, permitindo identificar segmentos lineares correspondentes às marcações de faixa mesmo quando parcialmente ocluídos ou fragmentados [8], [9].

Embora os métodos clássicos apresentem eficiência computacional e desempenho adequado em cenários controlados — como rodovias com faixas bem demarcadas, iluminação uniforme e trajetórias retilíneas —, eles tendem a apresentar limitações em situações mais complexas [8]. A detecção torna-se desafiadora em curvas acentuadas, onde a modelagem por linhas retas não representa adequadamente a geometria parabólica ou de clothoide das faixas; em condições de iluminação irregular, como sombras projetadas por árvores ou veículos, que geram falsas bordas; ou em faixas desgastadas ou parcialmente apagadas, onde o contraste insuficiente compromete a detecção de bordas [9]. Adicionalmente, esses métodos exigem ajustes manuais de parâmetros (como limiares de detecção) para se adaptarem a diferentes cenários, reduzindo sua generalização e robustez em ambientes reais de condução.

A segunda abordagem engloba métodos baseados em aprendizado profundo (Deep Learning), que representam o estado da arte atual em detecção de faixas. Essas técnicas empregam CNNs treinadas em grandes conjuntos de dados anotados, permitindo que o modelo aprenda automaticamente representações hierárquicas de características visuais relevantes — desde bordas e texturas em camadas iniciais até

padrões semânticos complexos como curvatura e continuidade de faixas em camadas profundas [12]. Entre as arquiteturas especializadas desenvolvidas para detecção de faixas, destacam-se: SCNN (Spatial Convolutional Neural Network), proposto por Pan et al. (2018) [26], que incorpora camadas convolucionais espaciais para propagar informações contextuais entre pixels em diferentes regiões da imagem mediante mensagem sequencial em quatro direções (cima, baixo, esquerda, direita). Essa arquitetura foi avaliada no dataset TuSimple, alcançando 96,53% de acurácia na detecção de faixas, superando métodos baseline em 3-5%, especialmente em cenários com oclusões causadas por veículos ou sombras, demonstrando capacidade de reconstruir faixas parcialmente visíveis por meio de inferência contextual. De forma complementar, Neven et al. (2018) [27] propuseram o LaneNet, uma arquitetura de segmentação de instâncias que combina um ramo de segmentação binária (identificando pixels pertencentes a faixas) com um ramo de embedding discriminativo, que agrupa pixels da mesma faixa e separa faixas distintas no espaço de características aprendido. O modelo foi treinado e avaliado no dataset TuSimple, atingindo precisão de 96,4% e tempo de inferência de 52 ms por frame em GPU NVIDIA GTX 1080 Ti, viabilizando processamento em tempo real para aplicações automotivas. Adicionalmente, Hou et al. (2019) [28] desenvolveram o ENet-SAD (Efficient Neural Network with Self Attention Distillation), que emprega destilação de conhecimento via mecanismos de auto-atenção, permitindo que uma rede compacta (ENet) aprenda representações de uma rede mais profunda (ResNet). Essa abordagem alcançou 70,6% de acurácia no desafiador dataset CULane — que contém 133.235 frames com nove cenários complexos (neblina, chuva, sombras intensas, sem marcações visíveis) — mantendo velocidade de inferência de 250 FPS em GPU, demonstrando viabilidade para sistemas embarcados em veículos.

Uma vantagem dos métodos baseados em aprendizado profundo reside na capacidade de detectar faixas curvas e realizar segmentação pixel a pixel, gerando máscaras binárias que delimitam a área ocupada por cada faixa na imagem [12]. Essa granularidade espacial permite estimar a geometria da via, incluindo raio de curvatura e largura da faixa, informações relevantes para sistemas de condução autônoma e assistida. Adicionalmente, essas arquiteturas mantêm desempenho consistente em condições adversas — como chuva, neblina, baixa luminosidade ou faixas parcialmente desgastadas — pois aprendem padrões robustos a partir da diversidade de cenários presentes nos dados de treinamento [12].

No contexto da presente pesquisa, a integração entre detecção de faixas e rastreamento ocular viabiliza uma análise multimodal do comportamento de condução. A detecção de faixas fornece a de-

limitação objetiva das áreas críticas do ambiente viário, enquanto o rastreamento ocular quantifica onde e por quanto tempo o motorista dirige a atenção visual. Essa combinação permite investigar hipóteses específicas sobre padrões de atenção segura, como verificar se condutores experientes fixam o olhar com maior frequência nas delimitações laterais da via durante manobras de mudança de faixa, ou se motoristas inexperientes apresentam dispersão atencional excessiva para áreas não relevantes do cenário [13]. Ademais, os dados obtidos por meio dessa integração podem ser utilizados para treinar modelos de aprendizado de máquina capazes de classificar comportamentos de risco, gerando alertas em tempo real quando padrões atencionais inadequados são detectados, ou oferecendo programas personalizados de treinamento visual para correção de hábitos de condução inseguros.

Referências

- [1] World Health Organization, *Road Traffic Injuries*, <https://www.who.int/news-room/fact-sheets/detail/road-traffic-injuries>, Accessed: 2023-12-13, dez. de 2023.
- [2] R. E. Amini, C. Al Haddad, D. Batabyal, I. Gkena e G. Markkula, “Driver Distraction and In-Vehicle Interventions: A Driving Simulator Study on Visual Attention and Driving Performance,” *Accident Analysis & Prevention*, vol. 191, p. 108 682, 2023. DOI: 10.1016/j.aap.2023.108682.
- [3] N. Behboudi, S. Moosavi e R. Ramnath, “Recent Advances in Traffic Accident Analysis and Prediction: A Comprehensive Review of Machine Learning Techniques,” *arXiv preprint arXiv:2406.13968*, 2024. arXiv: 2406.13968. URL: <https://arxiv.org/pdf/2406.13968>.
- [4] F. Aydin, G. Caruso e L. Mussone, “An Image Processing-Based Method to Analyze Driver Visual Behavior Using Eye-Tracker Data,” *Applied Sciences*, vol. 14, n.º 14, p. 6123, 2024. DOI: 10.3390/app14146123.
- [5] C. Y. Arias-Portela, J. Mora-Vargas e M. Caro, “Situational Awareness Assessment of Drivers Boosted by Eye-Tracking Metrics: A Literature Review,” *Applied Sciences*, vol. 14, n.º 4, p. 1611, 2024. DOI: 10.3390/app14041611.
- [6] D. D. Salvucci e J. H. Goldberg, “Identifying fixations and saccades in eye-tracking protocols,” em *Proceedings of the symposium on Eye tracking research & applications*, 2000, pp. 71–78.
- [7] T. W. Victor, J. L. Harbluk e J. A. Engström, “Sensitivity of eye-movement measures to in-vehicle task difficulty,” *Transportation Research Part F: Traffic Psychology and Behaviour*, vol. 8, n.º 2, pp. 167–190, 2005.

- [8] S. Yenikaya, G. Yenikaya e E. Düven, "Keeping the vehicle on the road: A survey on on-road lane detection systems," *ACM Computing Surveys*, vol. 46, n.º 1, pp. 1–43, 2013.
- [9] A. B. Hillel, R. Lerner, D. Levi e G. Raz, "Recent progress in road and lane detection: A survey," *Machine Vision and Applications*, vol. 25, n.º 3, pp. 727–745, 2014.
- [10] Y. Wu, A. Kirillov, F. Massa, W.-Y. Lo e R. Girshick, *Detectron2*, <https://github.com/facebookresearch/detectron2>, 2019.
- [11] K. He, G. Gkioxari, P. Dollár e R. Girshick, "Mask R-CNN," em *Proceedings of the IEEE International Conference on Computer Vision*, 2017, pp. 2961–2969.
- [12] D. Feng, A. Harakeh, S. L. Waslander e K. Dietmayer, "Deep multi-modal object detection and semantic segmentation for autonomous driving: Datasets, methods, and challenges," *IEEE Transactions on Intelligent Transportation Systems*, vol. 22, n.º 3, pp. 1341–1360, 2020.
- [13] G. Underwood, P. Chapman, N. Brocklehurst, J. Underwood e D. Crundall, "Eye movements and hazard perception in active and passive driving," *Visual Cognition*, vol. 10, n.º 7, pp. 845–867, 2003.
- [14] P. R. Chapman e G. Underwood, "Visual search patterns in trained and untrained novice drivers," *Transportation Research Part F: Traffic Psychology and Behaviour*, vol. 1, n.º 2, pp. 157–167, 1998.
- [15] S. K. Lal e A. Craig, "A critical review of the psychophysiology of driver fatigue," *Biological Psychology*, vol. 55, n.º 3, pp. 173–194, 2001.
- [16] D. F. Dinges e R. Grace, "PERCLOS: A valid psychophysiological measure of alertness as assessed by psychomotor vigilance," *Federal Highway Administration, Publication Number FHWA-MCRT-98-006*, 1998.
- [17] H. J. Foy e P. Chapman, "Mental workload is reflected in driver behaviour and physiological responses," *Applied Ergonomics*, vol. 73, pp. 90–99, 2018.
- [18] A. Sahayadhas, K. Sundaraj e M. Murugappan, "Detecting driver drowsiness based on sensors: A review," *Sensors*, vol. 12, n.º 12, pp. 16 937–16 953, 2012.
- [19] M. Kassner, W. Patera e A. Bulling, "Pupil: An open source platform for pervasive eye tracking and mobile gaze-based interaction," em *Proceedings of the 2014 ACM International Joint Conference on Pervasive and Ubiquitous Computing: Adjunct Publication*, ACM, 2014, pp. 1151–1160.
- [20] Pupil Labs, *Pupil Core: Mobile Eye Tracking Hardware*, <https://pupil-labs.com/products/core>, Accessed: 2024-10-28, 2020.
- [21] T. Santini, W. Fuhl, D. Geisler e E. Kasneci, "EyeRecToo: Open-source software for real-time pervasive head-mounted eye tracking," *Proceedings of VISIGRAPP*, vol. 2, pp. 96–101, 2018.
- [22] S. Ren, K. He, R. Girshick e J. Sun, "Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks," em *Advances in Neural Information Processing Systems*, vol. 28, 2015, pp. 91–99.
- [23] T.-Y. Lin, P. Goyal, R. Girshick, K. He e P. Dollár, "Focal Loss for Dense Object Detection," em *Proceedings of the IEEE International Conference on Computer Vision*, 2017, pp. 2980–2988. DOI: 10.1109/ICCV.2017.324.
- [24] J. Canny, "A Computational Approach to Edge Detection," em *IEEE Transactions on Pattern Analysis and Machine Intelligence*, IEEE, vol. PAMI-8, 1986, pp. 679–698. DOI: 10.1109/TPAMI.1986.4767851.
- [25] R. O. Duda e P. E. Hart, "Use of the Hough Transformation to Detect Lines and Curves in Pictures," *Communications of the ACM*, vol. 15, n.º 1, pp. 11–15, 1972. DOI: 10.1145/361237.361242.
- [26] X. Pan, J. Shi, P. Luo, X. Wang e X. Tang, "Spatial as Deep: Spatial CNN for Traffic Scene Understanding," em *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 32, 2018, pp. 7276–7283. DOI: 10.1609/aaai.v32i1.12301.
- [27] D. Neven, B. De Brabandere, S. Georgoulis, M. Proesmans e L. Van Gool, "Towards End-to-End Lane Detection: an Instance Segmentation Approach," *2018 IEEE Intelligent Vehicles Symposium (IV)*, pp. 286–291, 2018. DOI: 10.1109/IVS.2018.8500547.
- [28] Y. Hou, Z. Ma, C. Liu e C. C. Loy, "Learning Lightweight Lane Detection CNNs by Self Attention Distillation," em *Proceedings of the IEEE/CVF International Conference on Computer Vision*, 2019, pp. 1013–1021. DOI: 10.1109/ICCV.2019.00110.